

ĐẠI HỌC BÁCH KHOA
ĐẠI HỌC QUỐC GIA TP HCM
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



HỌC MÁY
(C03117)

Báo cáo tiến độ
Lần thứ ba - Ngày 12/04/2026

Giảng viên hướng dẫn: TS. Trương Vĩnh Lân
Nhóm thực hiện: Nhóm 10

Họ và tên	MSSV	Ghi chú
Trần Gia Hân	2052464	Nhóm trưởng <i>han.tran2202@hcmut.edu.vn</i>
Lê Minh Mẫn	2312040	
Nguyễn Thành Trình	2313640	
Ngô Quang Tân	2313052	
Lương Mạnh Tiến	2213459	

Mục lục

1	Tổng quan tiến độ	1
2	Kết quả EDA và Tiền xử lý (Tóm tắt)	1
3	Classical Machine Learning Pipeline	2
3.1	Trích xuất đặc trưng	2
3.2	Baseline Training	2
3.2.1	Kết quả Baseline	3
3.2.2	Nhận xét Baseline	3
3.3	Hyperparameter Tuning	3
3.3.1	Phương pháp	3
3.3.2	Không gian siêu tham số	4
3.3.3	Nhận xét kết quả Tuning	4
3.4	So sánh Best Baseline và Best Tuned Model	4
3.5	Lựa chọn mô hình cuối cùng cho Classical Pipeline	5
3.6	Phân tích Feature Importance	5
4	Deep Learning Pipeline – Tiến độ ban đầu	5
4.1	Kiến trúc mô hình học sâu	6
4.2	Kết quả sơ bộ	6
4.3	Kế hoạch tiếp theo cho Deep Learning	6
5	Tiến độ so với kế hoạch	6
6	Phân công công việc thực tế	7

1 Tổng quan tiến độ

Báo cáo tiến độ lần thứ ba ghi nhận việc hoàn thành **Classical Machine Learning Pipeline** (Pipeline truyền thống), bao gồm trích xuất đặc trưng, huấn luyện baseline, tinh chỉnh siêu tham số và phân tích đặc trưng quan trọng. Ngoài ra, nhóm đã bắt đầu triển khai **Deep Learning Pipeline** với các mô hình MLP và TabNet.

So với lộ trình đề ra trong báo cáo lần 1, nhóm đang **đúng tiến độ** tại mốc ngày 05/04/2026.

2 Kết quả EDA và Tiền xử lý (Tóm tắt)

Phần này tóm tắt các kết quả đã hoàn thành từ giai đoạn EDA và tiền xử lý (được trình bày chi tiết trong báo cáo lần 2).

- **Dataset:** Adult Census Income – 48.842 mẫu, 15 cột (14 đặc trưng + 1 nhãn mục tiêu `income`).
- **Xử lý missing value:** thay thế ký tự ? bằng NaN, sau đó áp dụng *Most Frequent Imputation* (điền giá trị xuất hiện nhiều nhất) cho cột categorical.
- **Loại bỏ cột dư thừa:** cột `education` (trùng thông tin với `educational-num`) và `fnlwgt` (trọng số điều tra, không liên quan đến bài toán) đã được loại bỏ.
- **Encoding** (mã hóa đặc trưng): One-Hot Encoding cho các cột categorical; StandardScaler cho các cột numerical.
- **Kết quả preprocessing:** tổng cộng **91 features** sau khi mã hóa và chuẩn hóa.
- **Tỉ lệ train/test:** 80/20, phân tầng theo nhãn (*stratified split*).

3 Classical Machine Learning Pipeline

3.1 Trích xuất đặc trưng

Nhóm xây dựng hai nhánh đặc trưng để so sánh song song:

- **Full features:** giữ nguyên toàn bộ 91 đặc trưng sau preprocessing.
- **PCA 95%** (PCA – phân tích thành phần chính, giữ lại 95% phương sai): fit trên tập train rồi transform tập test, thu được **25 thành phần chính** (giảm từ 91 xuống 25 chiều).

Lưu ý: PCA chỉ được fit trên tập train và transform trên tập test để tránh *data leakage* (rò rỉ thông tin từ tập kiểm tra sang quá trình huấn luyện).

3.2 Baseline Training

Bốn mô hình học máy truyền thống được huấn luyện trên cả hai nhánh đặc trưng:

1. **Logistic Regression** – mô hình tuyến tính, huấn luyện nhanh, dùng làm baseline tham chiếu.
2. **Linear SVM** (máy vector hỗ trợ tuyến tính) – hiệu quả tính toán tốt hơn SVM-RBF trên tập lớn; `class_weight="balanced"` để xử lý mất cân bằng lớp.
3. **Random Forest** (rừng ngẫu nhiên) – mô hình ensemble phi tuyến, 100 cây quyết định, mô hình hóa tương tác giữa các đặc trưng.
4. **Gaussian Naive Bayes** (mô hình xác suất Bayes đơn giản giả định phân phối Gaussian) – hiệu quả trên không gian đặc trưng sau PCA.

Tất cả các mô hình có hỗ trợ đều được cấu hình `class_weight="balanced"` để bù đắp sự mất cân bằng lớp (76% vs 24%).

3.2.1 Kết quả Baseline

Bảng 1 tóm tắt kết quả baseline theo F1-score giảm dần trên các chỉ số chính. Metric chính được dùng để đánh giá là **F1-score** do dữ liệu có mất cân bằng lớp nhẹ.

Table 1: Kết quả baseline – sắp xếp theo F1-score giảm dần

Feature Set	Mô hình	Accuracy	Precision	Recall	F1-score	ROC-AUC
full_features	Linear SVM	0.812	0.582	0.832	0.685	–
full_features	Logistic Regression	0.808	0.574	0.839	0.682	0.898
full_features	Random Forest	0.856	0.712	0.653	0.681	0.924
pca_95	Linear SVM	0.803	0.565	0.832	0.673	–
pca_95	Logistic Regression	0.801	0.561	0.836	0.671	0.892
pca_95	Random Forest	0.842	0.679	0.633	0.655	0.905
pca_95	Gaussian Naive Bayes	0.726	0.440	0.805	0.569	0.840
full_features	Gaussian Naive Bayes	0.723	0.437	0.804	0.566	0.837

3.2.2 Nhận xét Baseline

- **Nhánh full_features** cho kết quả tốt hơn hoặc tương đương **pca_95** trên hầu hết mô hình, cho thấy PCA làm mất một phần thông tin có ích với bài toán này.
- **Random Forest** đạt accuracy cao nhất (0.856) nhưng F1-score tương đương Logistic Regression, xác nhận rằng accuracy không nên là chỉ số duy nhất khi dữ liệu có mất cân bằng lớp.
- Với lớp >50K, mô hình Logistic Regression có recall = 0.84 nhưng precision = 0.57, nghĩa là mô hình phát hiện được phần lớn mẫu thu nhập cao nhưng còn nhiều false positive.
- **Gaussian Naive Bayes** có F1-score thấp nhất, do giả định độc lập có điều kiện không phù hợp với dữ liệu có tương quan giữa các đặc trưng.

3.3 Hyperparameter Tuning

Dựa trên kết quả baseline, nhóm chọn nhánh **full_features** làm nhánh chính cho bước tinh chỉnh siêu tham số.

3.3.1 Phương pháp

- **Cross-validation**: Stratified K-Fold với $k = 5$ folds để đánh giá ổn định và giữ tỉ lệ lớp qua các fold.
- **GridSearchCV**: Logistic Regression, Linear SVM, Gaussian Naive Bayes (không gian tham số nhỏ, duyệt đầy đủ).

- **RandomizedSearchCV** với `n_iter=15`: Random Forest (không gian tham số lớn, cân bằng thời gian chạy và phạm vi tìm kiếm).
- **Metric tối ưu hóa**: F1-score trên lớp dương (>50K).

3.3.2 Không gian siêu tham số

Table 2: Không gian siêu tham số tìm kiếm

Mô hình	Siêu tham số	Giá trị tìm kiếm
Logistic Regression	<code>C</code> (hệ số điều chuẩn) <code>solver</code>	[0.01, 0.1, 1.0, 10.0] [liblinear]
Linear SVM	<code>C</code>	[0.01, 0.1, 1.0, 10.0]
Random Forest	<code>n_estimators</code> (số cây) <code>max_depth</code> (độ sâu tối đa) <code>min_samples_split</code> <code>min_samples_leaf</code>	[100, 150, 200] [None, 10, 20, 30] [2, 5, 10] [1, 2, 4]
Gaussian Naive Bayes	<code>var_smoothing</code>	[10^{-12} , 10^{-10} , 10^{-9} , 10^{-8} , 10^{-7}]

3.3.3 Nhận xét kết quả Tuning

- Nâng số fold từ 3 lên 5 giúp đánh giá ổn định hơn, giảm phương sai kết quả cross-validation.
- **Random Forest** sau tuning cải thiện rõ rệt cả F1-score và ROC-AUC so với baseline.
- Logistic Regression và Linear SVM cải thiện nhẹ, vẫn thấp hơn Random Forest trên ROC-AUC.
- Gaussian Naive Bayes cải thiện không đáng kể.

3.4 So sánh Best Baseline và Best Tuned Model

Table 3: So sánh mô hình baseline tốt nhất và mô hình tuned tốt nhất

Giai đoạn	Mô hình	Feature Set	Acc.	Prec.	Recall	F1	AUC
Best Baseline	Logistic Regression	full_features	0.808	0.574	0.839	0.682	0.898
Best Tuned	Random Forest	full_features	0.870	0.746	0.665	0.703	0.931

Random Forest sau tinh chỉnh tham số cải thiện F1-score thêm $\approx +0.021$ và ROC-AUC thêm $\approx +0.033$ so với baseline tốt nhất.

3.5 Lựa chọn mô hình cuối cùng cho Classical Pipeline

Dựa trên kết quả thực nghiệm, nhóm chọn **Random Forest sau tuning** làm mô hình cuối cùng của classical pipeline vì:

1. **F1-score là chỉ số chính** – cân bằng precision và recall, phù hợp với dữ liệu mất cân bằng lớp.
2. **ROC-AUC cao nhất (0.931)** – khả năng phân biệt hai lớp tốt trên nhiều ngưỡng quyết định.
3. **Phù hợp với dữ liệu tabular** – học được quan hệ phi tuyến và tương tác đặc trưng.
4. **Hỗ trợ feature importance** – cho phép phân tích và diễn giải kết quả mô hình.
5. **Không cần PCA** – hoạt động tốt trực tiếp trên full features mà không cần giảm chiều.

3.6 Phân tích Feature Importance

Nhóm phân tích feature importance của mô hình Random Forest sau tuning. Top-15 đặc trưng quan trọng nhất cho thấy:

- **capital-gain**: đặc trưng quan trọng nhất – mặc dù phân phối lệch mạnh (đa số bằng 0), nhưng khi > 0 rất tương quan với thu nhập cao.
- **educational-num**: trình độ học vấn dạng số – phản ánh mối liên hệ trực tiếp giữa giáo dục và thu nhập.
- **age**: độ tuổi – nhóm 40–60 tuổi có xác suất thu nhập cao hơn.
- **hours-per-week**: số giờ làm việc mỗi tuần – quan hệ thuận chiều với thu nhập.
- **marital-status_Married-civ-spouse**: tình trạng đã kết hôn – đặc trưng categorical có đóng góp lớn nhất trong nhóm One-Hot.
- **capital-loss**: khi > 0 là tín hiệu phân biệt quan trọng.
- **occupation_***: các nhóm nghề nghiệp như Exec-managerial, Prof-specialty có đóng góp đáng kể.

Kết quả này **nhất quán với phân tích EDA** từ báo cáo lần 1, trong đó age, education, hours-per-week và occupation được nhận định có tương quan cao với target.

4 Deep Learning Pipeline – Tiến độ ban đầu

Song song với việc hoàn thiện classical pipeline, nhóm đã bắt đầu triển khai **Deep Learning Pipeline** (notebook 04_deep_learning.ipynb).

4.1 Kiến trúc mô hình học sâu

Hai mô hình học sâu được xây dựng:

- **MLP** (Multilayer Perceptron – mạng nơ-ron nhiều lớp fully-connected): kiến trúc với nhiều lớp ẩn, Batch Normalization (chuẩn hóa theo batch), Dropout (tắt ngẫu nhiên nơ-ron để tránh overfitting) và hàm kích hoạt ReLU. Tối ưu hóa bằng Adam với learning rate scheduling.
- **TabNet**: kiến trúc học sâu chuyên biệt cho dữ liệu dạng bảng, sử dụng cơ chế attention (chú ý) để tự động chọn đặc trưng quan trọng tại mỗi bước xử lý.

4.2 Kết quả sơ bộ

Dựa trên kết quả thực nghiệm hiện tại, mô hình tốt nhất của toàn bộ pipeline là **MLP** với F1-score đạt **0.6881** trên tập test.

4.3 Kế hoạch tiếp theo cho Deep Learning

- Tinh chỉnh siêu tham số MLP (số lớp ẩn, dropout rate, learning rate, batch size).
- Thực nghiệm với SMOTE (kỹ thuật tăng cường mẫu thiểu số tổng hợp – tạo thêm mẫu lớp thiểu số nhân tạo) để xử lý mất cân bằng lớp cho DL pipeline.
- Hoàn thiện TabNet và so sánh với MLP.
- So sánh tổng thể: classical pipeline (Random Forest) vs deep learning (MLP/TabNet).

5 Tiến độ so với kế hoạch

Table 4: Đối chiếu tiến độ thực tế với kế hoạch đề ra

Mốc thời gian	Kế hoạch	Thực tế
08/03/2026	Setup, EDA sơ bộ, kế hoạch triển khai	✓ Hoàn thành
22/03/2026	Hoàn thiện preprocessing, bắt đầu classical pipeline	✓ Hoàn thành
05/04/2026	Hoàn thiện classical pipeline, bắt đầu deep learning	✓ Hoàn thành
19/04/2026	Hoàn thiện deep learning, so sánh, kiểm tra tổng thể	Đang triển khai
10/05/2026	Hoàn chỉnh toàn bộ	–

6 Phân công công việc thực tế

Table 5: Phân công công việc thực tế giai đoạn 2 – 3

Nội dung	Số thành viên	Trạng thái
Preprocessing (<code>preprocessing.py</code>)	1	✓ Hoàn thành
Classical pipeline – baseline training	2	✓ Hoàn thành
Classical pipeline – tuning & evaluation	2	✓ Hoàn thành
Deep Learning – MLP	1	Đang hoàn thiện
Deep Learning – TabNet	1	Đang triển khai
So sánh tổng thể & báo cáo cuối	Cả nhóm	Chưa bắt đầu