

ĐẠI HỌC BÁCH KHOA
ĐẠI HỌC QUỐC GIA TP HCM
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



HỌC MÁY
(C03117)

Báo cáo tiến độ

Lần thứ hai - ngày 22/03/2026

Giảng viên hướng dẫn: TS. Trương Vĩnh Lân
Nhóm thực hiện: Nhóm 10

Họ và tên	MSSV	Ghi chú
Trần Gia Hân	2052464	Nhóm trưởng <i>han.tran2202@hcmut.edu.vn</i>
Lê Minh Mẫn	2312040	
Nguyễn Thành Trình	2313640	
Ngô Quang Tân	2313052	
Lương Mạnh Tiến	2213459	

Mục lục

1	Bài toán và dữ liệu	2
2	Phân tích khám phá dữ liệu (EDA)	2
3	Tiền xử lý dữ liệu (Preprocessing)	7
4	Kết quả hiện tại	9
5	Hướng phát triển tiếp theo	10

1 Bài toán và dữ liệu

Bài toán: Xây dựng mô hình học máy để dự đoán mức thu nhập của một cá nhân dựa trên các thông tin nhân khẩu học và nghề nghiệp. Loại bài toán: Phân loại nhị phân. Biến mục tiêu: $income \leq 50K$ $> 50K$ Bộ dữ liệu sử dụng: Adult Income Dataset. Đầu vào: Các thuộc tính như tuổi, trình độ học vấn, nghề nghiệp, tình trạng hôn nhân, số giờ làm việc mỗi tuần, capital-gain, capital-loss, v.v. Đầu ra: Nhân thu nhập của từng cá nhân. Mục tiêu của giai đoạn hiện tại: Khảo sát và hiểu dữ liệu Thực hiện EDA Xây dựng và so sánh các phương án tiền xử lý phù hợp trước khi bước sang giai đoạn huấn luyện mô hình hoàn chỉnh

- Bài toán: Xây dựng mô hình học máy để dự đoán mức thu nhập của một cá nhân dựa trên các thông tin nhân khẩu học và nghề nghiệp.
- Loại bài toán: Phân loại nhị phân.
- Biến mục tiêu: **income**
 - $\leq 50k$
 - $> 50k$
- Bộ dữ liệu sử dụng: Adult Income Dataset
- Đầu vào: Các thuộc tính như tuổi, trình độ học vấn, nghề nghiệp, tình trạng hôn nhân, số giờ làm việc mỗi tuần, capital-gain, capital-loss, v.v.
- Đầu ra: Nhân thu nhập của từng cá nhân.
- Mục tiêu của giai đoạn hiện tại:
 - Khảo sát và hiểu dữ liệu
 - Thực hiện EDA
 - Xây dựng và so sánh các phương án tiền xử lý phù hợp trước khi bước sang giai đoạn huấn luyện mô hình hoàn chỉnh.

2 Phân tích khám phá dữ liệu (EDA)

Ở giai đoạn này, nhóm tiến hành khảo sát tổng quan bộ dữ liệu để hiểu rõ hơn về cấu trúc, kiểu dữ liệu, phân bố các thuộc tính và mối liên hệ giữa chúng với biến mục tiêu.

```
# [EDA 1.2] Display dataset structure
df.info()

*** <class 'pandas.core.frame.DataFrame'>
RangeIndex: 48842 entries, 0 to 48841
Data columns (total 15 columns):
#   Column                Non-Null Count  Dtype
---  -
0    age                    48842 non-null  int64
1    workclass              48842 non-null  object
2    fnlwgt                48842 non-null  int64
3    education             48842 non-null  object
4    educational-num       48842 non-null  int64
5    marital-status        48842 non-null  object
6    occupation            48842 non-null  object
7    relationship          48842 non-null  object
8    race                  48842 non-null  object
9    gender                48842 non-null  object
10   capital-gain          48842 non-null  int64
11   capital-loss          48842 non-null  int64
12   hours-per-week        48842 non-null  int64
13   native-country        48842 non-null  object
14   income                48842 non-null  object
dtypes: int64(6), object(9)
memory usage: 5.6+ MB
```

Figure 1: Cấu trúc tổng quan của dữ liệu

Cụ thể, nhóm đã kiểm tra số lượng mẫu, các kiểu dữ liệu của từng cột, tình trạng missing value và các giá trị bất thường như dấu ? trong một số thuộc tính categorical. Bên cạnh đó, nhóm cũng quan sát phân phối của biến mục tiêu và phân tích một số đặc trưng quan trọng như age, education / educational-num, hours-per-week, capital-gain và capital-loss.

```
# [EDA 1.3] Count the number of '?' in each column
print((df == '?').sum())

*** age                0
workclass            2799
fnlwgt               0
education            0
educational-num      0
marital-status       0
occupation           2809
relationship         0
race                 0
gender               0
capital-gain         0
capital-loss         0
hours-per-week       0
native-country       857
income               0
dtype: int64
```

Figure 2: Output kiểm tra giá trị dấu '?'




Figure 3: Biểu đồ phân phối của biến mục tiêu `income`

Biến mục tiêu `income` có sự mất cân bằng nhẹ với tỷ lệ xấp xỉ 76% thuộc lớp `<=50K` và 24% thuộc lớp `>50K`. Điều này cần được lưu ý khi lựa chọn metric đánh giá mô hình, trong đó F1-score sẽ phù hợp hơn so với chỉ dùng `accuracy`.

Phân tích đặc trưng categorical theo target

Nhóm phân tích ba biến categorical có khả năng phân biệt target tốt gồm `education`, `occupation` và `marital-status`.




Figure 4: Phân phối `education` theo `income` (chuẩn hóa)

Biểu đồ cho thấy trình độ học vấn có liên hệ rõ rệt với thu nhập. Các nhóm `Doctorate`, `Prof-school` và `Masters` có tỷ lệ `>50K` cao nhất, trong khi các nhóm học vấn thấp như `Preschool`,

1st-4th gần như không có quan sát nào thuộc lớp >50K. Đây là một trong những đặc trưng có khả năng phân biệt target mạnh nhất trong bộ dữ liệu.




Figure 5: Phân phối occupation theo income (chuẩn hóa)

Về nghề nghiệp, Exec-managerial và Prof-specialty có tỷ lệ thu nhập >50K cao nhất, trong khi Priv-house-serv và Farming-fishing gần như hoàn toàn thuộc lớp <=50K.




Figure 6: Phân phối marital-status theo income (chuẩn hóa)

Tình trạng hôn nhân cũng cho thấy sự phân biệt rõ ràng: nhóm Married-civ-spouse và

Married-AF-spouse có tỷ lệ >50K cao hơn hẳn so với các nhóm còn lại như Never-married hay Separated.

Phân tích đặc trưng numerical theo target




Figure 7: Phân phối age theo income




Figure 8: Phân phối hours-per-week theo income

Nhóm >50K có độ tuổi trung vị cao hơn và phân phối tập trung hơn so với nhóm <=50K. Tương tự, nhóm thu nhập cao làm việc nhiều giờ hơn mỗi tuần với trung vị khoảng 45 giờ so với 40 giờ của nhóm còn lại. Cả hai đặc trưng này đều có khả năng đóng góp vào việc phân biệt hai lớp thu nhập.

Thông qua bước EDA, nhóm có cái nhìn rõ hơn về đặc điểm của dữ liệu, từ đó làm cơ sở để lựa chọn các hướng tiền xử lý phù hợp ở bước tiếp theo.

3 Tiền xử lý dữ liệu (Preprocessing)

Sau bước EDA, nhóm tiến hành xây dựng quy trình tiền xử lý để chuẩn bị dữ liệu cho giai đoạn huấn luyện mô hình. Các bước chính bao gồm chuẩn hóa missing value, loại bỏ đặc trưng dư thừa, chia tập train/test và xây dựng pipeline tiền xử lý riêng cho từng nhóm đặc trưng.

Chuẩn hóa missing value

Dữ liệu gốc mã hóa giá trị thiếu bằng ký hiệu ? thay vì NaN. Nhóm thực hiện thay thế toàn bộ giá trị ? bằng NaN trước khi đưa vào pipeline.

```
# [Preprocessing 2.1] Replace '?' with NaN
df_prep = df.copy()
df_prep.replace('?', np.nan, inplace=True)

df_prep.isnull().sum()

***
age      0
workclass 2799
fnlwgt    0
education 0
educational-num 0
marital-status 0
occupation 2809
relationship 0
race      0
gender     0
capital-gain 0
capital-loss 0
hours-per-week 0
native-country 857
income     0

dtype: int64
```

Figure 9: Kết quả sau khi chuẩn hóa missing value

Ba cột có missing value là `workclass` (2799 giá trị, 5.73%), `occupation` (2809 giá trị, 5.75%) và `native-country` (857 giá trị, 1.75%). Tỷ lệ thiếu không quá lớn nên nhóm giữ lại dữ liệu và


xử lý bằng imputation trong pipeline.

Loại bỏ đặc trưng dư thừa

Dựa trên kết quả EDA, nhóm loại bỏ hai cột:

- **education**: trùng lặp thông tin với **educational-num** — mỗi mức của **education** tương ứng đúng một giá trị của **educational-num**, nên chỉ cần giữ lại cột số.
- **fnlwgt**: là sampling weight của điều tra dân số, không mô tả trực tiếp đặc điểm cá nhân và không có ý nghĩa dự đoán trong bài toán phân loại thu nhập.

Phân loại đặc trưng



```
# (Preprocessing 2.4) Identify numerical and categorical columns
num_features = x.select_dtypes(include=['int64', 'float64']).columns.tolist()
cat_features = x.select_dtypes(include=['object']).columns.tolist()

print("Numerical features:", num_features)
print("Categorical features:", cat_features)

--- Numerical features: ['age', 'educational-num', 'capital-gain', 'capital-loss', 'hours-per-week']
Categorical features: ['workclass', 'marital-status', 'occupation', 'relationship', 'race', 'gender', 'native-country']
```

Figure 10: Phân loại biến numerical và categorical

Sau khi loại bỏ, tập đặc trưng gồm 12 biến được chia thành hai nhóm:

- **Numerical** (5 biến): **age**, **educational-num**, **capital-gain**, **capital-loss**, **hours-per-week**
- **Categorical** (7 biến): **workclass**, **marital-status**, **occupation**, **relationship**, **race**, **gender**, **native-country**

Chia tập train/test

Dữ liệu được chia theo tỷ lệ 80/20 với **stratify=y** để giữ phân phối lớp ổn định giữa hai tập, đảm bảo việc đánh giá mô hình trên tập test đáng tin cậy.

So sánh các cấu hình preprocessing

Để chọn cấu hình preprocessing phù hợp, nhóm xây dựng bốn cấu hình khác nhau và sử dụng Logistic Regression làm mô hình đánh giá cố định. Các cấu hình được thay đổi theo ba yếu tố: cách điền missing value ở biến categorical, cách scaling biến numerical, trong đó tất cả đều dùng One-Hot Encoding cho biến categorical.

Cấu hình	Imputation	Scaling	Acc.	Prec.	Recall	F1
config_2	constant ("Missing")	StandardScaler	0.8554	0.7461	0.5997	0.6649
config_4	most_frequent	None	0.8531	0.7403	0.5950	0.6597
config_1	most_frequent	StandardScaler	0.8522	0.7375	0.5937	0.6578
config_3	most_frequent	MinMaxScaler	0.8526	0.7440	0.5854	0.6553

Table 1: So sánh hiệu năng các cấu hình preprocessing (đánh giá bằng Logistic Regression, metric tính trên lớp >50K)

Kết quả cho thấy **config_2** đạt F1-score cao nhất (0.6649). Việc điền missing value bằng nhãn riêng "Missing" giúp mô hình phân biệt được sự vắng mặt của thông tin với các giá trị thực, thay vì che khuất thông tin thiếu bằng giá trị phổ biến nhất. Nhóm chọn cấu hình này cho các bước huấn luyện mô hình tiếp theo.

4 Kết quả hiện tại

Đến thời điểm hiện tại, nhóm đã hoàn thành các bước chính gồm khảo sát dữ liệu, EDA và xây dựng các cấu hình tiền xử lý cho bộ dữ liệu. Thông qua các bước này, nhóm đã nắm được một số đặc điểm quan trọng của dữ liệu như sự xuất hiện của giá trị thiếu dạng ?, sự chênh lệch giữa hai lớp của biến mục tiêu, cũng như một số đặc trưng đáng chú ý cần được xử lý trước khi huấn luyện mô hình.

Bên cạnh đó, nhóm đã thử nghiệm sơ bộ ba mô hình phân loại cơ bản trên cấu hình preprocessing tốt nhất để quan sát kết quả ban đầu và định hướng cho giai đoạn tiếp theo.

Mô hình	Accuracy	Precision	Recall	F1-score
Decision Tree	0.8621	0.7808	0.5894	0.6710
Random Forest	0.8645	0.8036	0.5740	0.6697
Logistic Regression	0.8554	0.7461	0.5997	0.6649

Table 2: So sánh kết quả sơ bộ giữa các mô hình (metric tính trên lớp >50K)

Kết quả cho thấy Decision Tree đạt F1-score cao nhất (0.6710), trong khi Random Forest có accuracy và precision cao nhất nhưng recall thấp hơn. Logistic Regression đóng vai trò baseline và cho kết quả ổn định. Nhóm sẽ tiếp tục tinh chỉnh tham số và so sánh chi tiết hơn ở giai đoạn tiếp theo.

5 Hướng phát triển tiếp theo

Trong giai đoạn tiếp theo, nhóm sẽ tiếp tục hoàn thiện phần modeling dựa trên dữ liệu đã được tiền xử lý. Trước mắt, nhóm sẽ sử dụng cấu hình preprocessing phù hợp để huấn luyện và so sánh một số mô hình cơ bản, từ đó chọn ra hướng triển khai hiệu quả hơn cho bài toán.

Sau đó, nhóm sẽ tiếp tục đánh giá kết quả giữa các mô hình, xem xét tinh chỉnh tham số nếu cần, đồng thời hoàn thiện pipeline tổng thể cho bài toán dự đoán thu nhập. Mục tiêu ở giai đoạn sau là cải thiện hiệu quả dự đoán và chuẩn bị phần tổng hợp kết quả cho báo cáo cuối.