

ĐẠI HỌC BÁCH KHOA
ĐẠI HỌC QUỐC GIA TP.HCM
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



HỌC MÁY
(C03117)

Báo cáo tiến độ

Lần thứ nhất - ngày 08/03/2026

Giảng viên hướng dẫn: TS. Trương Vĩnh Lân
Nhóm thực hiện: Nhóm 10

Họ và tên	MSSV	Ghi chú
Trần Gia Hân	2052464	Nhóm trưởng <i>han.tran2202@hcmut.edu.vn</i>
Lê Minh Mẫn	2312040	
Nguyễn Thành Trình	2313640	
Ngô Quang Tân	2313052	
Lương Mạnh Tiến	2213459	

Mục lục

1	Mục tiêu và Bài toán	2
2	Giới thiệu Dataset	2
3	Phân tích sơ bộ (EDA sơ bộ)	2
4	Kế hoạch triển khai	4
4.1	Kế hoạch Pipeline	4
4.2	Phân công công việc	5
4.3	Lộ trình triển khai dự kiến	5
4.4	Môi trường triển khai bài tập lớn	5

1 Mục tiêu và Bài toán

Bài tập lớn nhằm xây dựng một pipeline học máy hoàn chỉnh cho dữ liệu dạng bảng. Bao gồm các bước EDA, tiền xử lý, trích xuất đặc trưng, huấn luyện và đánh giá mô hình.

Bài toán cụ thể là phân loại nhị phân: dự đoán thu nhập cá nhân có vượt 50.000 USD/năm hay không, dựa trên các đặc trưng nhân khẩu học.

- Input là các thông tin như *age*, *occupation*, *education*, *hours-per-week* và các đặc trưng nhân khẩu học khác.
- Output là nhân $\leq 50K$ hoặc $> 50K$

2 Giới thiệu Dataset

- Tên Dataset: Adult Census Income
- Nguồn gốc : UCI Machine Learning Repository
- Nguồn truy cập: <https://www.kaggle.com/datasets/wenrui/adult-income-dataset>
- Số mẫu: 48.842
- Số cột: 15 (14 đặc trưng + 1 target)
- Target: *income* - nhị phân, phân phối 76% ($\leq 50K$) / 24% ($> 50K$)
- Missing values: tồn tại dưới dạng ký tự ?, cần thay thế bằng NaN trong bước tiền xử lý
- Cột Categorical: *workclass*, *education*, *marital-status*, *occupation*, *relationship*, *race*, *gender*, *native-country*
- Cột Numerical: *age*, *fnlwgt*, *educational-num*, *capital-gain*, *capital-loss*, *hours-per-week*

3 Phân tích sơ bộ (EDA sơ bộ)

- Bảng thống kê mô tả các cột numerical:

Cột	Min	Max	Mean	Std
Age	17	90	38.64	13.71
education-num	1	16	10.08	2.57
capital-gain	0	99999	1079.07	7452.02
capital-loss	0	4356	87.50	402.96
hours-per-week	1	99	40.42	12.39

- Bảng missing value:

Cột	Số lượng	Tỷ lệ
workclass	2799	5.73%
occupation	2809	5.75%
native-country	857	1.75%

- Phân phối target: mất cân bằng nhẹ (76/24), cần lưu ý khi chọn metric đánh giá
- Cột *education* và *education-num* chứa thông tin trùng nhau (một dạng chữ, một dạng số) – > dự kiến loại bỏ *education* trong bước tiền xử lý dữ liệu
- Các cột *capital-gain* và *capital-loss* có phân phối lệch mạnh - đa số bằng 0
- Nhận xét sơ bộ: *age*, *education*, *hours-per-week*, *occupation* có khả năng tương quan cao với *target*
- Bộ dataset thỏa đầy đủ yêu cầu đề bài: có missing values tự nhiên, có categorical value đa dạng, sample size đủ lớn (48.842 mẫu)




Figure 1: Phân phối target (income)




Figure 2: Tỷ lệ missing value (%)




Figure 3: Phân phối age và hours-per-week theo income




Figure 4: Correlation heatmap (numerical features)

4 Kế hoạch triển khai

4.1 Kế hoạch Pipeline

- Tiền xử lý:

- Xử lý missing value: Most Frequent Imputation, KNN Imputation (k=5)
- Encoding categorical: One-Hot Encoding, Label Encoding

- Scaling numerical: StandardScaler, MinMaxScaler

- **Trích xuất đặc trưng:**

- Thử PCA trên dữ liệu số hoá sau tiền xử lý
- Đồng thời cân nhắc so sánh với phương án không giảm chiều

- **Mô hình dự kiến**

- Logistic Regression
- SVM
- Random Forest
- Multilayer Perceptron

- **Đánh giá dự kiến**

- Do dữ liệu có mất cân bằng nhẹ, ngoài accuracy, nhóm sẽ chú trọng thêm precision, recall và F1-score để đánh giá mô hình toàn diện hơn
- So sánh pipeline truyền thống và mô hình học sâu về hiệu năng, độ ổn định và mức độ phù hợp với dữ liệu tabular.

4.2 Phân công công việc

Nội dung	Số thành viên phụ trách	Ghi chú ngắn
EDA + preprocessing	1	Khảo sát dữ liệu, missing value, encoding
Pipeline truyền thống	2	Huấn luyện, tuning, đánh giá
Deep Learning + So sánh	2	Xây dựng mô hình học sâu, so sánh kết quả, tổng hợp

4.3 Lộ trình triển khai dự kiến

Mốc thời gian	Nội dung
08/03/2026	Setup, EDA sơ bộ, kế hoạch triển khai
22/03/2026	Hoàn thiện tiền xử lý, bắt đầu triển khai Pipeline truyền thống
05/04/2026	Hoàn thiện Pipeline truyền thống, bắt đầu Pipeline Học sâu
19/04/2026	Hoàn thiện Pipeline Học sâu, so sánh, kiểm tra tổng thể, hoàn thiện notebooks
10/05/2026	Hoàn chỉnh toàn bộ

4.4 Môi trường triển khai bài tập lớn

- Sử dụng GitHub repository để làm việc.



- Quy trình làm việc: mỗi công việc sẽ được thực hiện trên branch riêng, nhóm trưởng sẽ review và merge vào main
- Môi trường chạy: Google Colab